Universidad del Valle de Guatemala

Deep Learning

Laboratorio 7

Fabián Morales

Embeddings en PyTorch y gensim

nn.Embedding es una tabla de num_embeddings filas por embedding_dim columnas que devuelve el vector de cada ID sin construir vectores one-hot. padding_idx deja en ceros la fila de relleno y le quita el gradiente, y sparse=True produce un gradiente disperso con solo las filas del lote, útil con vocabularios grandes y aceptado por SGD, SparseAdam y Adagrad. nn.Embedding.from_pretrained crea la capa desde una matriz entrenada y su parámetro freeze decide si queda congelada o se ajusta con fine-tuning. nn.EmbeddingBag busca y agrega los vectores de cada bolsa con mode mean, sum o max, y con un tensor 1D de IDs concatenados más offsets, que marcan el inicio de cada bolsa, procesa documentos de distinto largo sin relleno. En gensim, Word2Vec entrena en CPU con vector_size, window, min_count, sg, negative, sample, alpha y epochs, y KeyedVectors ofrece most_similar, most_similar_cosmul, evaluate_word_analogies y evaluate_word_pairs.

CBOW predice la palabra central desde el promedio de su contexto y es más rápido, mientras que skip-gram predice cada palabra del contexto desde la central y representa mejor las palabras raras. Word2Vec usa W para la palabra como centro y W' como contexto porque con una sola matriz cada palabra tendería a predecirse a sí misma, y al final conserva W. Word2Vec es predictivo y aprende ventana por ventana con negative sampling, mientras que GloVe primero cuenta la matriz global de co-ocurrencias y luego ajusta productos punto que aproximan su logaritmo.

Datos y preprocesamiento

Se usó completo el entrenamiento de WikiText-103: 28,472 artículos, 1,801,350 líneas, 1,165,029 no vacías y 101.4 millones de tokens crudos. La normalización sigue las convenciones de GloVe para que los vocabularios sean comparables: minúsculas, reconstrucción de las marcas para obtener well-known, 1,000 y 3.5, contracciones separadas como do y n't, abreviaturas como u.s. en un token, números conservados y puntuación eliminada. En 12 oraciones el tokenizador propio coincidió con NLTK en 5 y con spaCy en 6. Los tres separan igual las contracciones, spaCy parte guiones como well-known y e-mail, NLTK y spaCy conservan el punto de dr. y jan., y el propio parte 10:30 y o'neill.

Quedan 84.6 millones de tokens y 725,273 palabras distintas. La ley de Zipf se cumple entre los rangos 10 y 10,000, con pendiente log-log de −0.94, y la cola cae más rápido, con −1.71. Las 10, 1,000 y 30,000 palabras más frecuentes cubren el 24.6, 64.0 y 94.6 % de los tokens. Con min_count de 3, 5, 10 y 20 el vocabulario es de 273,143, 194,103, 127,819 y 86,083 palabras, con 0.65, 0.97, 1.48 y 2.15 % de tokens desconocidos. Con t de 0.0001 el submuestreo descarta el 96.3 % de the, el 94.1 % de of y el 93.8 % de and, lo que quita pares poco informativos,

acelera cada epoch y acerca las palabras de contenido. Con ventana 5 hay 812.3 millones de pares por epoch antes del submuestreo y 480.0 millones después, y con la ventana dinámica de Word2Vec son 490.7 y 291.4 millones.

Iteraciones de skip-gram

El SGNS propio usa dos tablas nn.Embedding dispersas, negativos de la distribución unigrama a la 0.75 y SGD con learning rate lineal desde 0.025, en lotes de 32,768 pares generados en la GPU. Sumar en un solo paso los gradientes de palabras muy frecuentes hizo divergir a NaN las configuraciones con 15 negativos, t de 0.001 o learning rate de 0.05, por lo que el gradiente de cada fila se recorta a ±5. Cada iteración cambia un hiperparámetro respecto a S1, y S14 combina los que mejoraron el promedio entre analogías y WordSim-353, sin usar SimLex-999.

Tabla 1. Iteraciones de skip-gram

Iter.	Cambio	Tokens M	Vocab.	Pérdida	Sem.	Sint.	Total	WS353	s por epoch	Total s	Pico MB
S1	base	84.6	194,103	2.157	0.406	0.580	0.524	0.691	32.3	161	4,136
S2	dimensión 50	84.6	194,103	2.194	0.281	0.461	0.403	0.646	24.9	125	4,050
S3	dimensión 300	84.6	194,103	2.107	0.565	0.627	0.607	0.694	61.7	309	4,482
S4	25 % del corpus	21.0	194,103	2.150	0.282	0.429	0.382	0.637	8.2	41	3,397
S5	50 % del corpus	42.3	194,103	2.153	0.372	0.536	0.483	0.676	16.5	83	3,657
S6	ventana 2	84.6	194,103	2.043	0.360	0.601	0.524	0.670	17.1	85	2,696
S7	ventana 10	84.6	194,103	2.211	0.411	0.549	0.505	0.684	57.5	287	6,429
S8	15 negativos	84.6	194,103	3.066	0.471	0.588	0.550	0.681	63.1	316	4,155
S9	t 1e-3	84.6	194,103	2.191	0.393	0.581	0.521	0.693	45.7	229	4,999
S10	t 1e-5	84.6	194,103	2.087	0.423	0.537	0.500	0.670	20.6	103	2,923
S11	min_count 20	84.6	86,083	2.192	0.398	0.592	0.530	0.689	34.7	174	4,000
S12	lr 0.05	84.6	194,103	2.147	0.417	0.574	0.524	0.690	35.9	180	4,136
S13	10 epochs	84.6	194,103	2.137	0.440	0.598	0.547	0.701	36.0	360	4,136
S14	15 negativos, min_count 20, 10 epochs	84.6	86,083	3.101	0.505	0.601	0.570	0.681	64.5	645	4,015

Una pérdida más baja no implica mejores embeddings. S6 tiene la más baja porque predecir vecinos inmediatos es fácil, y no supera a S1, mientras que S8 y S14 tienen la más alta porque suman 15 negativos y logran el mejor accuracy de dimensión 100. Se eligió S14, porque S3 es mejor pero no es comparable con GloVe de 100 dimensiones.

Aritmética vectorial

La función propia analogia coincide exactamente con most_similar de gensim. En 18 analogías propias de 6 tipos, SGNS y gensim aciertan 16 en primer lugar y GloVe 15. Fallan germany:berlin :: italy:?, con vienna o venice, y big:bigger :: small:?, con larger. Para king − man + woman, queen tiene similitud 0.738 en SGNS y 0.770 en GloVe. Sin excluir la consulta, en 10 de 18 analogías gana una palabra de la consulta, casi siempre c, y la respuesta queda segunda. La tabla 2 usa las 30,000 palabras más frecuentes presentes en los tres modelos, con una cobertura de 62.3 %. El paralelismo es el coseno promedio entre los vectores diferencia de cada categoría, que para pares al azar es 0.000.

Tabla 2. Analogías por categoría

Categoría	Cober-tura	SGNS		gensim		GloVe		Paralelismo	
		Add	Mul	Add	Mul	Add	Mul	SGNS	GloVe
capital-common	0.91	0.727	0.693	0.682	0.673	0.937	0.920	0.39	0.59
capital-world	0.27	0.600	0.565	0.585	0.556	0.892	0.862	0.31	0.56
currency	0.10	0.000	0.011	0.000	0.011	0.045	0.034	0.22	0.26
city-in-state	0.73	0.383	0.362	0.388	0.368	0.306	0.269	0.20	0.34
family	0.68	0.637	0.605	0.629	0.599	0.880	0.868	0.31	0.51
adjective-to-adverb	0.76	0.243	0.212	0.228	0.192	0.295	0.294	0.16	0.28
opposite	0.42	0.246	0.178	0.234	0.155	0.254	0.219	0.11	0.23
comparative	0.95	0.698	0.686	0.698	0.680	0.800	0.780	0.36	0.42
superlative	0.63	0.405	0.403	0.415	0.423	0.608	0.613	0.31	0.47
present-participle	0.82	0.541	0.516	0.513	0.482	0.721	0.715	0.22	0.32
nationality-adjective	0.81	0.882	0.866	0.876	0.856	0.973	0.958	0.55	0.75
past-tense	0.85	0.723	0.700	0.727	0.706	0.588	0.562	0.25	0.29
plural	0.74	0.648	0.585	0.627	0.572	0.795	0.756	0.20	0.31
plural-verbs	0.81	0.440	0.463	0.450	0.472	0.578	0.598	0.31	0.36
semánticas	0.44	0.505	0.477	0.496	0.475	0.606	0.577	0.29	0.45
sintácticas	0.77	0.601	0.579	0.595	0.572	0.680	0.666	0.27	0.38
total	0.62	0.570	0.546	0.563	0.541	0.656	0.637	0.28	0.41

3CosMul queda entre 1 y 3 puntos debajo de 3CosAdd. Las categorías con diferencias más paralelas, como los gentilicios, son también las de mejor accuracy. En t-SNE se separan números, meses, animales, colores, deportes, familia, profesiones y verbos.

Comparación de los embeddings

Tabla 3. Comparación de los embeddings

Métrica	SGNS, S14	Word2Vec gensim	GloVe
Tokens del corpus	84.6 M	84.6 M	6,000 M
Vocabulario y dimensión	86,083 y 100	86,083 y 100	400,000 y 100
Tiempo de entrenamiento	645 s	852 s	85 min de conteo y 14 min por iteración
Hardware	GPU RTX 5070 Ti	CPU Ryzen 7 7800X3D	2 Xeon E5-2658
Analogías 3CosAdd, sem. sint. y total	0.505, 0.601, 0.570	0.496, 0.595, 0.563	0.606, 0.680, 0.656
Analogías 3CosMul, sem. sint. y total	0.477, 0.579, 0.546	0.475, 0.572, 0.541	0.577, 0.666, 0.637
Spearman WordSim-353	0.681	0.682	0.533
Spearman SimLex-999	0.309	0.306	0.296
Coseno entre diferencias	0.280	0.278	0.405
% tokens OOV en AG News	3.77	3.77	0.92
F1 de test en AG News	0.9156	0.9153	0.9194

El tiempo de GloVe es el que reportan sus autores, con vectores de 300 dimensiones y 32 núcleos.

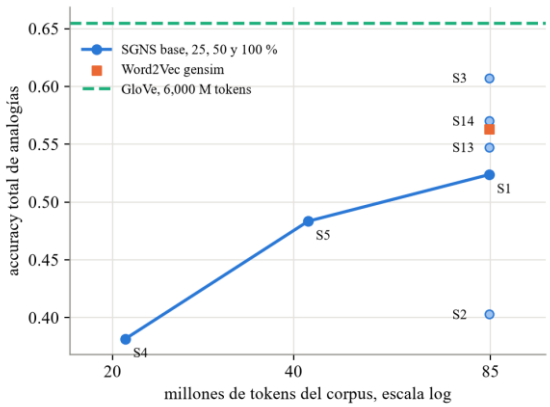


Figura 1. Analogías contra tamaño del corpus

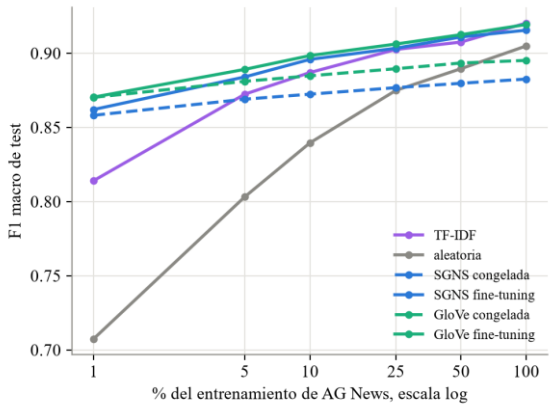


Figura 2. F1 contra datos de entrenamiento

Clasificación de AG News

Se usó el mismo tokenizador con 108,000 noticias de entrenamiento, 12,000 de validación estratificada y 7,600 de test. El clasificador promedia los vectores con nn.EmbeddingBag y aplica un MLP de 256 neuronas, y el baseline es TF-IDF de unigramas y bigramas con regresión logística.

Tabla 4. Clasificación de AG News

Modelo	Val acc	Val prec	Val rec	Val F1	Paráme-tros	Entre-nables	Tiempo s	Test F1
TF-IDF	0.9247	0.9246	0.9248	0.9246	1,696,120	1,696,120	31.2	0.9204
Aleatoria	0.9113	0.9112	0.9113	0.9112	4,972,284	4,972,284	4.0	0.9049
SGNS congelada	0.8867	0.8866	0.8867	0.8865	4,972,284	26,884	3.3	no aplica
SGNS fine-tuning	0.9234	0.9235	0.9234	0.9233	4,972,284	4,972,284	3.8	0.9156
gensim congelada	0.8888	0.8890	0.8888	0.8887	4,972,284	26,884	3.3	no aplica
gensim fine-tuning	0.9227	0.9229	0.9227	0.9227	4,972,284	4,972,284	3.9	0.9153
GloVe congelada	0.9018	0.9019	0.9018	0.9016	4,972,284	26,884	3.4	no aplica
GloVe fine-tuning	0.9231	0.9237	0.9231	0.9229	4,972,284	4,972,284	3.9	0.9194

Con fine-tuning la validación empeora desde la epoch 3 o 4 por overfitting, mientras que las variantes congeladas mejoran hasta la epoch 10. Todos los modelos confunden sobre todo Business con Sci/Tech.

Análisis y discusión

La aritmética vectorial se cumple como aproximación: SGNS acierta el 57.0 % de las analogías. Funciona mejor en gentilicios, capitales, pasado y comparativos, y falla en monedas, opuestos y adjetivo a adverbio. Las sintácticas, con 60.1 %, superan a las semánticas, con 50.5 %, porque siguen patrones morfológicos frecuentes, mientras que las semánticas exigen ver muchas veces cada entidad.

El "≈" no es una igualdad. Sin excluir la consulta, el vecino más cercano de king − man + woman es king y queen queda segunda. Además, las diferencias de una relación tienen coseno promedio de 0.28, unos 74 grados, así que la suma solo desplaza el punto un poco hacia la respuesta.

El modelo quedó 8.6 puntos debajo de GloVe en analogías, sobre todo en semánticas. El corpus explica una parte con rendimientos decrecientes, porque del 25 al 50 % se ganaron 10.2 puntos y del 50 al 100 % solo 4.0. Los hiperparámetros pesan igual: con los mismos datos S14 ganó 4.6 puntos sobre S1 y la dimensión 300 ganó 8.4. En WordSim-353 y SimLex-999 el modelo propio supera a GloVe.

El SGNS propio se comporta como gensim, con 57.0 % frente a 56.3 % en analogías y 0.916 frente a 0.915 de F1. Las pequeñas diferencias vienen de actualizar por lotes con recorte y no par por par, y de las semillas.

De 50 a 300 dimensiones el accuracy subió 20.4 puntos y con 15 negativos subió 2.7, a cambio de más tiempo. Las ventanas pequeñas favorecen lo sintáctico: con ventana 2 las sintácticas suben a 60.1 % y las semánticas bajan a 36.0 %, y con ventana 10 las semánticas suben a 41.1 %.

En AG News los preentrenados con fine-tuning superaron a la tabla aleatoria, 0.916 y 0.919 frente a 0.905 de F1, pero no a TF-IDF, con 0.920. Con todos los datos convino el fine-tuning, que gana entre 2.4 y 3.3 puntos, y congelar solo conviene por costo. Con el 1 % de los datos congelar y ajustar dan casi lo mismo, y ambos superan a TF-IDF por más de 4 puntos y a la tabla aleatoria por más de 15.

Conclusiones

1. El SGNS propio en PyTorch reproduce a Word2Vec de gensim, con 57.0 % frente a 56.3 % de analogías y el mismo desempeño en clasificación.

2. La aritmética vectorial es una aproximación y no una igualdad: sin excluir la consulta gana una palabra de la consulta en 10 de 18 casos.

3. Los embeddings preentrenados son más útiles con pocos datos: con el 1 % superan a TF-IDF por más de 4 puntos, y con todos los datos TF-IDF los iguala.

Repositorio: https://github.com/FabianMoraeles/DeepLab7